

赵明, 陈石, 房立华等. 2019. 基于 U 形卷积神经网络的震相识别与到时拾取方法研究. 地球物理学报, 62(8): 3034-3042, doi:10.6038/cjg2019M0495.

Zhao M, Chen S, Fang L H, et al. 2019. Earthquake phase arrival auto-picking based on U-shaped convolutional neural network. *Chinese J. Geophys.* (in Chinese), 62(8): 3034-3042, doi:10.6038/cjg2019M0495.

基于 U 形卷积神经网络的震相识别与 到时拾取方法研究

赵明¹, 陈石¹, 房立华^{1*}, David A Yuen^{2,3}

1 中国地震局地球物理研究所, 北京 100081

2 美国哥伦比亚大学应用物理和应用数学系, 纽约 10027

3 中国地质大学大数据学院, 武汉 430074

摘要 精确获取震相到时是地震定位和地震走时成像等研究的重要基础. 近年来, 随着地震台站的不断加密, 地震台网监测到的地震数量成倍增长, 发展快速、准确、适用性强的震相到时自动拾取算法是地震行业的迫切需求. 本文在前人工作基础上, 发展了 Pg、Sg 震相自动识别与到时拾取的 U 网络算法(Unet_cea), 使用汶川余震和首都圈地震台网记录的 89344 个不同震级、不同信噪比的样本进行训练和测试. 研究表明, U 网络能够较好地识别 Pg、Sg 震相类型和拾取到时, Pg、Sg 震相的正确识别率分别为 81% 和 79.1%, 与人工标注到时的均方根误差分别为 0.41 s 和 0.54 s. U 网络在命中率、均方根误差等性能指标上均明显优于 STA/LTA 和峰度分析自动拾取方法. 研究获得的最优模型可以为区域地震台网的自动处理提供辅助.

关键词 U 网络; 震相识别; 区域地震台网; 汶川余震

doi:10.6038/cjg2019M0495

中图分类号 P631

收稿日期 2018-08-13, 2019-03-01 收修定稿

Earthquake phase arrival auto-picking based on U-shaped convolutional neural network

ZHAO Ming¹, CHEN Shi¹, FANG LiHua^{1*}, David A Yuen^{2,3}

1 Institute of Geophysics, China Earthquake Administration, Beijing 100081, China

2 Department of Applied Physics and Applied Mathematics, Columbia University, New York 10027, USA

3 Department of Big Data, China University of Geoscience, Wuhan 430074, China

Abstract Accurate seismic phase arrival time picking is the basis for earthquake location and seismic travel time tomography. With the increase of seismic stations and the improvement of monitoring capabilities, it is an urgent need to develop fast, accurate and adaptable algorithms. Based on previous work, this paper developed a U-shaped neural network (Unet_cea) for Pg and Sg phase detection and arrival time picking, and trained model on 89344 waveform samples with different magnitudes and signal-to-noise ratio levels from Wenchuan aftershocks and the Beijing capital circle seismic network. The research shows that the U-net can recognize Pg and Sg phases with high correct rate, 81% and 79.1% respectively. Compared with manual picks, the mean square root errors of Pg and Sg are 0.41 s and 0.54 s, respectively. The U-net is superior to the

基金项目 国家重点研发计划(2018YFC1503400), 国家自然科学基金(41774067, 41804047), 中国地震局地球物理研究所基本科研业务专项(DQJB1801)及中国地震局监测预报司自动编目专项资助.

第一作者简介 赵明, 男, 1984 年生, 助研, 主要从事地震数据自动处理方法研究. E-mail: mzhao@cea-igp.ac.cn

* 通讯作者 房立华, 男, 1981 年生, 博士, 研究员, 主要从事地震学和地球内部结构研究. E-mail: flh@cea-igp.ac.cn

STA/LTA and kurtosis analysis methods in performance and has higher hit rate and lower root mean square error. The optimal model obtained from the study can assist automatic cataloging work of the regional seismic networks.

Keywords U-net; Phase identification; Regional seismic networks; Wenchuan aftershocks

0 引言

基于地震台网的观测数据,编制地震观测报告(简称“地震编目”),是中国地震局地震监测工作的核心任务之一.这些数据是地震速报、地震预警等防震减灾工作的重要环节,也是地震层析成像、震源机制反演和地球内部结构等研究的重要基础.地震编目的主要内容包括震相识别、到时拾取、振幅和周期测量、初动极性标注和地震定位等工作,其中最重要的环节是震相识别和到时拾取.在区域台网中,最常见的震相是 Pg 和 Sg. Pg、Sg 分别指来自上地壳内震源的上行 P、S 波,或射线底部到达上地壳的 P、S 波,其震中距一般不超过 10° (中国地震局,2017).

传统的震相识别和到时拾取主要有人工处理和自动处理两种.人工识别主要依靠地震台网分析人员通过浏览连续波形,识别地震.这种方法效率低、主观性强、一致性差,尤其是遇到余震序列时,经常会漏掉地震.自动处理算法是根据波形在振幅、频率等方面的不同特征建立特征方程,进行检测.常用方法有:利用短时平均和长时平均比值的 STA/LTA 方法(Allen, 1978; Baer and Kradolfer, 1987; Withers et al., 1998),利用赤池信息准则寻找全局最小值作为震相到时的 AIC 方法(Akaike, 1974; Sleeman and Van Eck, 1999; Akazawa, 2004; 刘劲松等, 2013),以及利用偏度(Skewness)和峰度(Kurtosis)等反映数据分布形态的高阶统计量的偏度/峰度方法(Saragiotis et al., 2002; Küperkoch et al., 2010, 2012),等等.这些方法前人做过较多综述(刘翰林和吴庆举, 2017; 李力等, 2018).由于地震波形受仪器类型、环境噪声以及震源复杂性的影响,这些自动处理方法局限性也很明显,主要表现在如下方面:稳定性较差,不同的参数和阈值选择对结果影响很大;灵敏度较低,对信噪比较低的微震信号,检测效果往往难以达到预期;经常混淆 P、S 震相;S 震相到时拾取精度较低.

近年来,由于机器学习和深度学习技术的快速发展,国内外地震学家越来越多利用机器学习和深度学习对地震和噪声进行分类,如随机森林(Maggi et al., 2017)、支持向量机(Kortström et al., 2016;

蒋一然和宁杰远, 2019)、卷积神经网络(CNN)(Perol et al., 2018)等方法,参见 Kong 等(2018)的综述.其中,CNN 方法近两年来得到了较多应用,其强大之处在于多层结构的设计能自动学习不同层次的特征:较浅的卷积层能学习到一些局部特征,而较深的卷积层能够学习到更加抽象的特征,从而有助于同时提升模型分类能力和泛化能力.CNN 在地震与噪声分类、震相分类等问题上得到了较好应用,即使对一些低信噪比的数据,甚至肉眼难以识别的微震信号,也能有效甄别(如 Ross et al., 2018; 赵明等, 2019).然而,在震相到时拾取方面,机器学习和深度学习方法的拾取精度有待进一步提高.

2014 年,Long 等提出全卷积网络(FCN),使得 CNN 无需全连接层即可进行密集的像素预测,CNN 从而得到进一步普及(Long et al., 2015).Ronneberger 等在 FCN 基础上提出 U 网络并应用在医学图像分割上,取得了媲美专业医生的精准度(Ronneberger et al., 2015).U 网络的主要特点是不仅实现了输出层与输入层在分辨率上的一致性,还通过对称式的结构设计融合了 FCN 网络中的低维和高维特征.图像分割是对图像的每个像素进行分类,根据像素点对应的类别概率进行定位和边缘检测,与此十分类似,震相分类则是确定 P、S 波形的的位置,到时拾取则是寻找 P、S 对应的起震点.我们可以利用标注好到时及误差范围的地震 P、S 波形数据作为样本训练 U 网络模型,使其输出波形每个采样点所对应的 P、S 起震点概率,概率最大的采样点即为 P、S 到时.基于以上基本原理,本研究利用汶川地震余震和首都圈地震台网记录的 Pg、Sg 到时数据建立数据集,应用 U 网络进行 Pg、Sg 震相分类与到时拾取,并与 STA/LTA、Kurtosis 方法比较了震相识别正确率、拾取误差、漏检率,以及在不同信噪比水平下的表现进行了对比分析.

1 方法与数据

1.1 U 形神经网络

本研究在 Perol 等(2018)和 Zhu and Beroza (2019)的研究基础上,编写了基于 U 网络的震相识别

程序 (Unet_cea, https://github.com/mingzhaochina/unet_cea), 相比于经典 U 网络, 主要区别如下:

(1) 网络降维: U 网络默认为二维或三维图像数据所设计, 而地震波形数据为一维时间序列, 因此所有卷积层、池化层、drop out 层, 以及输入输出张量均需降为一维.

(2) 损失函数: 深度学习算法进行分类的数学原理实际是对目标函数进行最优化, 通过反复比较当前网络的预测值与我们期望的目标值的差异, 不断调整每一层的权重和偏差等超参数, 使得差值最小化. 衡量预测值与期望值差异的方程被称为损失函数 (或目标函数). 本研究采用的损失函数为

$$L = - \sum_{i=1}^3 \sum_{j=1}^n Y'_{ij} \cdot \log(Y_{ij}),$$

其中 Y' 为采用二值化编码的标签, $i=1, 2, 3$ 分别表示噪音、Pg、Sg, n 为波形采样点数, $j=1, \dots, n$ 为采样点序号, 其表达式为

$$Y'_i = \begin{cases} Y'_1: [1, 0, 0] \\ Y'_2: [0, 1, 0] \\ Y'_3: [0, 0, 1] \end{cases}$$

Y 为最后一层 softmax 函数计算得到概率值, 其表达式如下:

$$Y_i = \frac{e^{z_i}}{\sum_{k=1}^3 e^{z_k}},$$

其中 z 为最后一层的输出张量 ($[m, n, 3]$), m 为输入数据个数.

如图 1 所示, U 网络的基本组件为增采样层和降采样层. 降采样层由两个一维卷积层、一个池化层组成, 中间会随机加入一些 drop out 层来防止过拟合; 增采样层由一个转置卷积层、一个裁切层、一个卷积层组成, 同样根据情况适当加入 drop out 层. 网络输入为三分量地震波形. 根据前人在图像分割上的应用经验, 左半部分 4 个降采样层执行卷积和池化操作, 提取震相的抽象特征, 有助于解决震相定位的问题, 右半部分 4 个增采样层执行转置卷积和左右对称层之间互连通等操作, 可以逐步恢复震相的细节特征, 从而有助于解决震相分类的问题. 最后通过激活函数计算 Pg、Sg 或噪音概率值, 并与预设阈值比对确定该采样点的类别.

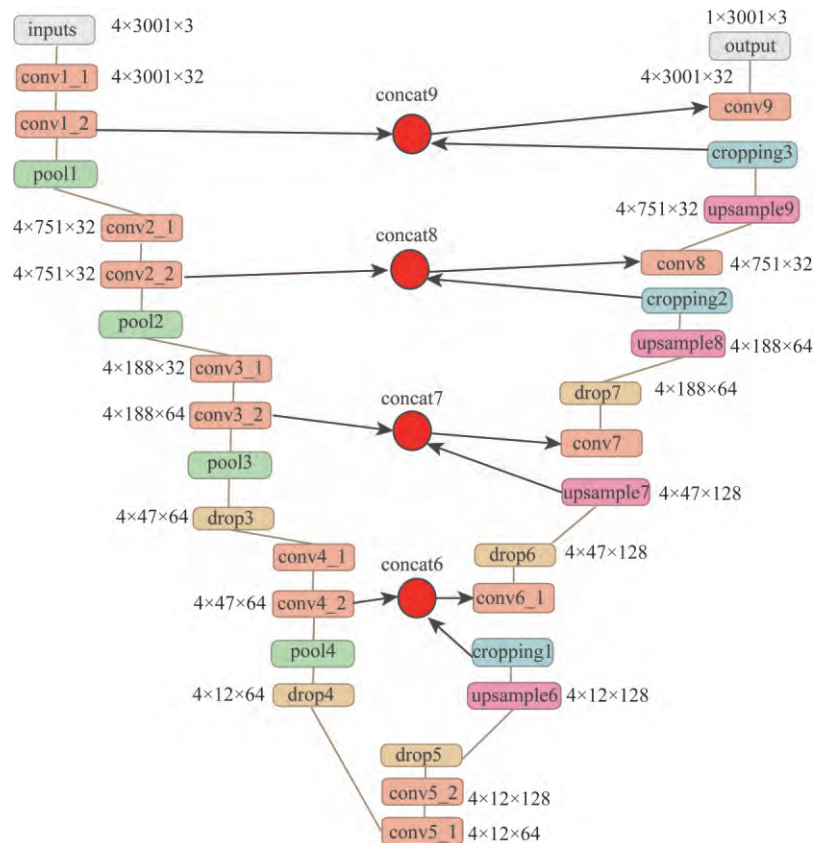


图 1 U 网络结构

每一层的参数含义为: 卷积核大小 \times 每通道特征数 \times 通道数.

Fig. 1 U-net structure

Each layer's parameters follow the format: Kernel size \times feature number per channel \times number of channels.

1.2 数据与预处理

与 CNN 网络一样, U 网络也需要大量预设样本进行训练. 本研究使用的样本数据来源于两部分: 一部分来自于 2017 年中国地震局地球物理研究所与阿里云联合举办的“余震捕捉—AI 大赛”(Fang et al., 2017), 包括 2008 年 6—8 月间汶川地震后震源区附近 15 个宽频带地震台站记录的数据, 数据信噪比水平集中于 2~5 之间(图 2a); 另一部分数据由北京数字遥测地震台网提供, 包含了首都圈地区 79 个地震台站 2014 年 1 月至 2015 年 8 月的连续波形数据和震相观测报告, 样本事件的震级主要分布在 $M_{0.0} \sim 2.0$, 信噪比集中分布在 1.6~5 区间(图 2b).

如图 3 的数据标注样本所示, 我们取 Pg 到前 3 s 至 Sg 到后 10 s 的波形, 并统一裁切为 30 s 长度(长度不足的以零值填充), 取 30 s 的原因是由于上述两个区域地震事件的震中距小于 150 km, Pg 和 Sg 到时差最大不会超过 25 s, 可以保证波形同时包含 Pg 和 Sg 震相. 然后对所有数据进行了去均值、归一化等预处理. 为了保证数据集质量, 我们手动对数据集进行了清洗, 更正较为明显的标注错误. 最终, 对汶川余震我们截取和标注的波形为 41722 段, 首都圈为 47622 段. 在训练集与验证集分配比例上, 我们使用 80% 的数据做训练, 剩余 20% 作为测

试. 汶川余震数据质量和到时精度很高, 震源较集中, 震级相对高, 适用于检测 U 网络模型的精度; 而首都圈地区台站分布广, 震源较分散, 微震事件多, 适合用于检测模型泛化能力.

此外, 我们采用了与赵明等(2019)相同的数据增强操作, 包括平移、加噪(模糊处理)、滤波, 并将预处理之后的数据集时间戳列表放在 <https://github.com/mingzhaochina/dataset>, 方便科研人员下载使用与测试.

1.3 U 网络模型训练与测试

我们使用 Keras(<https://keras.io>)构建 U 网络, 并在 tensorflow(<https://www.tensorflow.org>)上进行训练和测试. 在算法选择上使用了 L2 正则化以及随机梯度下降(SGD)算法来计算交叉熵损失函数, 以及 ADAM 优化算法、阶梯型学习率进一步优化计算过程. U 网络的训练在中国科学院网络中心(<http://www.cnict.cn>)进行, 使用 1 个计算节点(12 核 CPU, 64GB 内存, 1 块 Tesla P100 GPU 卡)上运行 8 个周期(epoch, 表示将所有样本遍历一遍)只需 15 min. 训练好的神经网络模型可以实时用于测试集, 对 9524 个测试样本的验证仅需 20 s.

训练及测试结果如图 4 所示. 其中在训练集上训练完第一个周期(约 5000 时间步)后精度即达到 98%, 之后的 7 个周期均稳定在这一水平(图 4a).

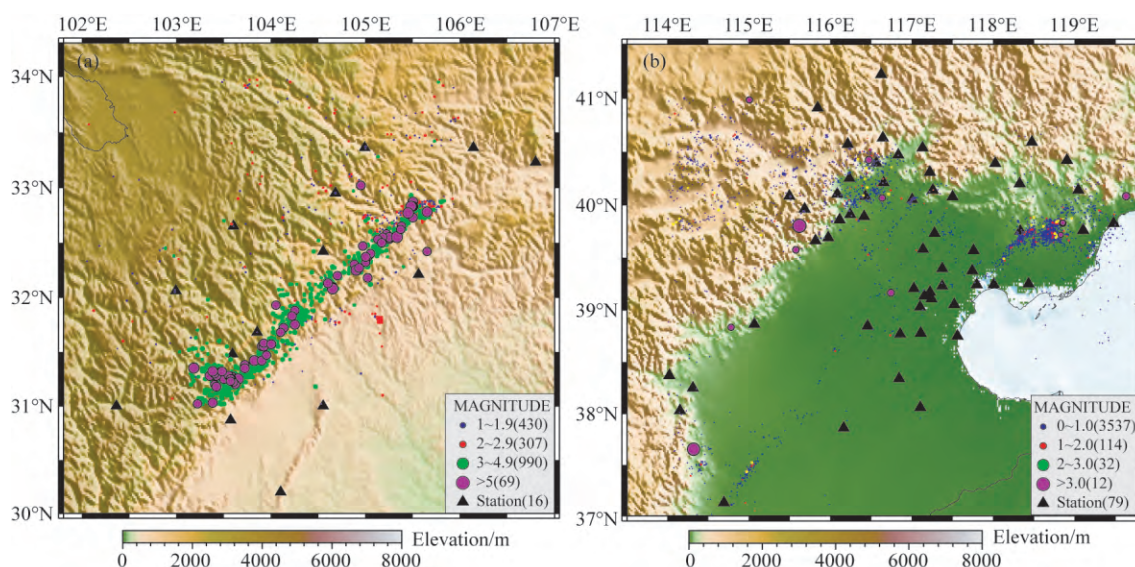


图 2 本研究使用的地震数据

(a) 汶川余震序列的震中及周边台站分布, 震级分布范围为 $M_{1.0} \sim 6.0$; (b) 首都圈地震震中及台站分布, 震级分布在 $M_{0.0} \sim 2.0$. 黑色三角为台站, 圆点为地震震中.

Fig. 2 Data used in this study

(a) Distribution of Wenchuan aftershocks and stations, the magnitude ranges from $M_{1.0}$ to 6.0; (b) Distribution of epicenters and stations in the Capital region, with magnitudes ranging from $M_{0.0}$ to 2.0. The black triangles represent station. The dots indicate earthquake epicenter.




图3 训练样本及标注示例

(a) 原始波形数据; (b) 噪声标签; (c) Pg 标签; (d) Sg 标签。虚线代表人工拾取的到时, 方框表示标签范围。由于人工标注会有一定误差, 所以 Pg 标签取人工时期到时附近 ± 0.25 s, Sg 标签取人工时期到时附近 ± 0.5 s。

Fig. 3 Samples and labels used in this study

(a) Original waveform; (b) Noise label; (c) Pg label; (d) Sg label. The dotted line represents manual picks and box indicates the range of label. The error bar used for Pg and Sg is ± 0.25 s and ± 0.5 s, respectively.

在测试集上 Pg、Sg 震相的识别正确率均随着训练时间的增加稳步上升: Pg 由 78% (20000 步) 至 86% (40000 步), Sg 由 74% (20000 步) 到 83.9% (40000 步), 这说明模型并没有发生过拟合, 并且训练时间越长, 精度越高。

2 首都圈台网震相挑取应用

我们将在训练集和测试集上表现最优的 U 网络模型, 应用于首都圈台网 2015 年 9—12 月间事件连续波形的震相挑取。首先根据河北省地震局提供的这一期间的人工编目报告 (包括发震时刻, 各台站记录的 Pg、Sg 到时等), 以地震事件的发震时间为开始, 以最远台站接收到 Sg 震相后 30 s 所对应的时间为止, 对各个台站统一截取三分量连续事件波形数据。然后每隔 2 s 依次取 30 s 长波形, 作为 U

网络的输入。由于输入的截断连续波形很大一部分是噪声, 或者只包含一部分震相, 因此其识别难度更大。为了客观评估 U 网络模型在连续波形应用中的性能, 我们选取了两种常用的震相拾取算法进行对比: STA/LTA 算法 (Krischer et al., 2015) 和 Kurtosis 算法 (Ross et al., 2016)。对于三种方法的检测结果, 参照人工编目到时作为标准答案评价。为保证结果可靠性, 我们仅选取人工编目结果中 ≥ 3 台以上同时监测到的事件, 最终确定了 2538 段标注波形。计算各种方法的均方根误差 (RMSE)、命中率 (H) 和查全率 (R), 三个指标的计算公式如下:

$$\text{RMSE} = \sqrt{\frac{1}{n \times m} \sum_{i=1}^n \sum_{j=1}^m [(T_{ij} - t_{ij})^2]},$$

$$H = T_e / (T_e + F_e),$$

$$R = T_e / (T_e + F_n).$$

(1) RMSE 为算法挑取到时 T_{ij} 与参考到时 t_{ij} 之间均方根误差, 用于反映算法到时挑取的精度, n 为台站数, m 是每个台的震相数, i, j 为序号;

(2) H 为正确率, 表示算法拾取的震相在误差范围内且与参考震相类型一致。 T_e 为自动算法到时检测正确的次数, F_e 为检测错误的次数。当自动拾取的到时与参考答案的差异小于一定阈值 (Pg 为 ± 0.25 s, Sg 为 ± 0.5 s), 且震相类型一致时, T_e 增加一次, 否则 F_e 增加一次;

(3) R 为查全率, 用于检查不同算法拾取的到时与参考到时相比的完整程度, 其中 F_n 为漏检的震相个数。

表1 U 网络与 Kurtosis、STA/LTA 算法结果对比

Table 1 Performance comparison between U-net, Kurtosis and STA/LTA method

方法	RMSE(s)		H		R	
	Pg	Sg	Pg	Sg	Pg	Sg
STA/LTA	0.49	0.62	58%	76.9%	40.5%	37.5%
Kurtosis	—	0.61	—	74.6%	—	39.6%
U 网络	0.41	0.54	81%	79.1%	49.6%	46.3%

计算结果如表 1 所示。总体而言, 在震相识别正确率上, U 网络对 Pg、Sg 震相的得分分别为 81% 和 79.1%, 均高于 STA/LTA 和 Kurtosis 方法的情况。在反映震相到时拾取精度的 RMSE 值上, U 网络拾取平均误差也比 STA/LTA 和 Kurtosis 方法的低。在反映震相识别完整性的查全率上, 三种方法都不是很高, 只有 U 网络接近一半, 这说明仍有相当数量的微震震相未被检测出来。图 5 给出了不同




图4 U 网络的训练与验证过程

(a) 训练精度; (b) 损失函数; (c) 验证集上的 P 波识别正确率; (d) 验证集上的 S 波识别正确率.

Fig. 4 U-net training and validation process

(a) Training accuracy; (b) Loss function; (c) Validation accuracy of P-wave; (d) Validation accuracy rate of S-wave.

情形下三种方法各自的震相到时拾取结果, 以及与人处理结果的对比.

3 讨论

实时地震学和地震早期预警都建立在对震相的准确快速识别上, 区域地震台网的日常编目工作也需要对大量波形进行分类与震相识别, 这些工作都迫切需要对地震数据的快速、高效和自动化处理. 由于地震的复杂多样性, 实现震相的自动化识别难度很大. 目前的震相自动识别技术很难同时在检测精度、稳定性和计算效率上都达到令人满意的水平.

本研究显示, U 网络具有良好的泛化能力. 对 9524 个具有不同信噪比、不同仪器类型、不同震级和震中分布的地震波形测试取得了 Pg 识别正确率最高 86% 和 Sg 最高 83.9% 的结果. 在识别难度更高的首都圈地震台网实际波形检测上, U 网络对 Pg、Sg 震相的正确识别率分别达到了 81% 和 79.1%, 与参考到时的均方根误差分别为 0.41 s 和 0.54 s, 这些指标均优于 STA/LTA、Kurtosis 等传统的自动检测方法.

尽管目前仍没有充分的理论阐明深度学习算法的具体工作过程, 但在测试数据集和连续波形数据上较高的检测正确率和较小的均方根误差表明, U 网络在获取震相特征上, 远比传统方法仅仅利用振

幅或频率等的一两种特征更加有效. 例如对于 Pg、Sg 到时相近的波形, Sg 常常受 Pg 尾波干扰甚至淹没, 传统方法基本很难给出有效的 Sg 到时, 而 U 网络不但能学习到 Pg、Sg 的特征, 还能区别二者到时的细微差异. 在计算量和耗时方面, 使用 GPU 卡加速的 U 网络算法明显优于模板匹配和波形相关等方法. 其主要计算开销来自模型的训练, 其余无论是测试集测试还是实际波形检测, 计算量和耗时都很低, 而且还可以迁移到其他地区进行应用.

目前, 将 U 网络用于实际波形的震相到时检测还存在两个主要问题:

(1) 漏检的事件偏多. 虽然 U 网络在实际波形检测中展示了与测试集一致的精度, 但这一一定程度上是由于我们的概率阈值较高 ($Y_i > 95\%$), 以及比对的人工标注波形质量较高 (≥ 3 台同时检测到). 如图 6 所示首都圈实际波形检测结果, 一部分波形未能预测或预测完全错误, 另一部分只给出了 Pg 或 Sg 预测. 我们对总计 1100 余段未能完全正确识别的波形进行了分析, 发现绝大多数 ($> 70\%$) 属于噪声干扰较大的复杂波形, 即使是人工检测结果也因人而异. 对这部分波形, 可以通过震相关联和定位来辅助确定其到时, 从而降低漏检率. 同时还有一小部分 ($< 30\%$) 属于信噪比较高、震相也比较清晰. 我们采用波形互相关方法计算其与训练样本之间的相关系数, 发现相关度均较低, 这说明这部分波形是我们训练样本中所缺失的特征, 应该进一步在类型上

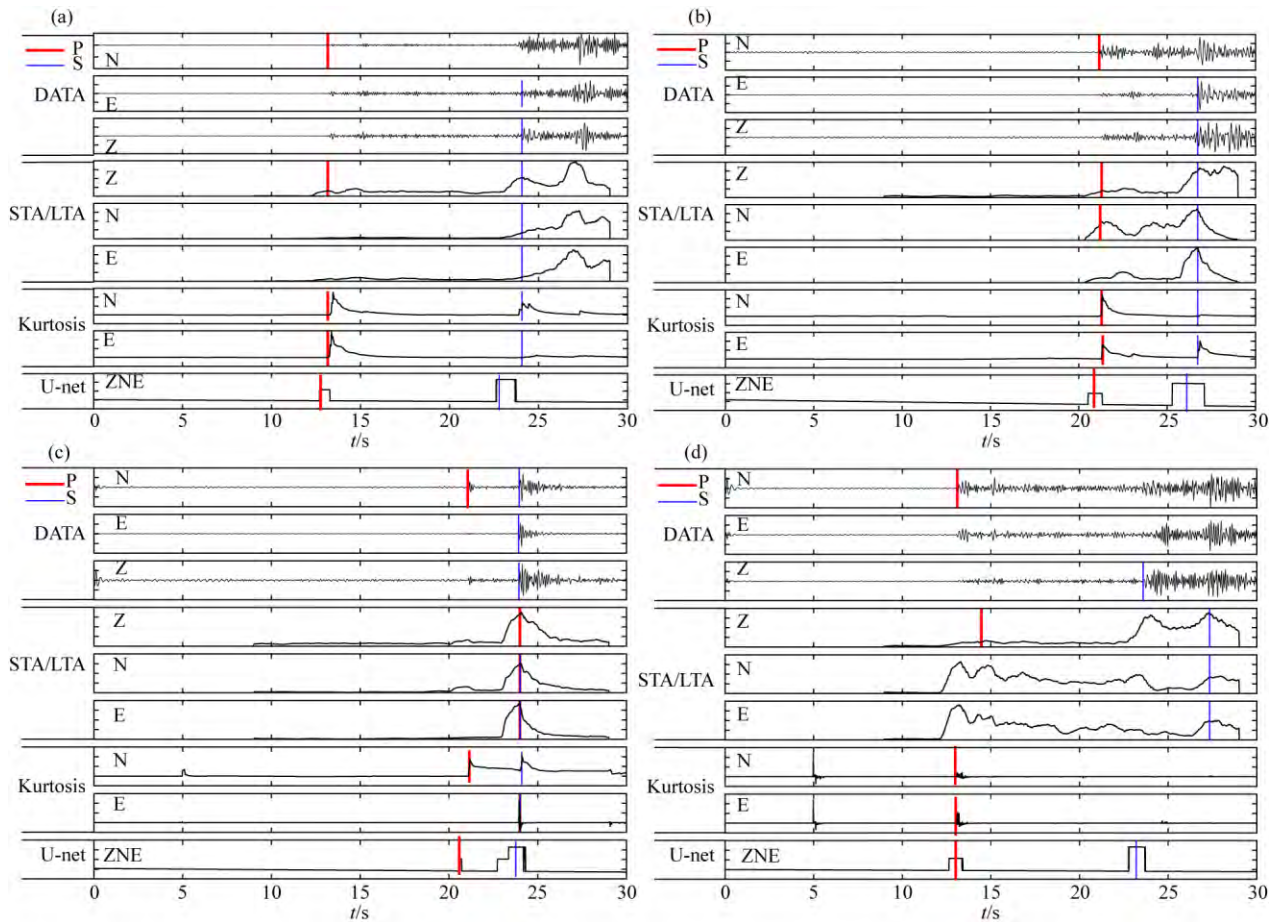


图 5 不同信噪比水平下人工挑选到时与 STA/LTA、Kurtosis、U 网络三种方法的自动拾取结果对比

(a) STA/LTA、Kurtosis 以及 U 网络都预测了正确的到时；(b) STA/LTA 对 Pg 预测错误，Kurtosis 和 U 网络预测正确；(c) STA/LTA 和 Kurtosis 分别预测对了二个震相，U 网络预测对二个震相；(d) STA/LTA 和 Kurtosis 对二个震相预测错误，U 网络给出正确预测。

Fig. 5 Comparison between manual picks and three automatic picking methods,

STA/LTA, Kurtosis and U-net at different SNR levels

(a) STA/LTA, Kurtosis and U-net all predict correctly; (b) STA/LTA predicts wrong Pg, while Kurtosis and U-net predict correctly; (c) STA/LTA and Kurtosis predict only one phase correctly, while U-net predicts both two phases correctly; (d) STA/LTA and Kurtosis predict wrong for both phases, while U-net gives correct prediction.

扩充训练样本数据,重新加以训练.此外由于在本研究中我们只使用了北京数字遥测地震台网一年的数据,在后续研究中使用 5—10 年的数据有望显著降低漏检率.

(2)震相到时挑取仍不够精确.如图 5 中不同方法的特征曲线所示,我们训练的 U 网络目前能够预测的 Pg、Sg 到时均有一定误差区间,分别为 ± 0.25 s 和 ± 0.5 s,而 STA/LTA 和 Kurtosis 等传统方法对波形的突变特征比较敏感,可达到 ± 0.2 s 甚至更低的拾取误差.当然,传统算法的劣势主要在于不够稳定,当数据信噪比低时,其精度大大降低,而此时 U 网络仍能保证相对稳定的输出.因此,U 网络于传统方法具有互补性,在实际应用中应当结合使用.例如,可以先设定一个较小的阈值,采用 STA/LTA

检测可能的震相到时,然后使用 U 网络确定震相类型和到时范围,然后再用 AIC、Kurtosis 等方法精确拾取震相到时.

4 结论

本研究使用四川地震台网和首都圈地震台网共 89344 个包含 Pg、Sg 标注震相的事件波形样本,训练和测试了一个可以进行震相识别和到时拾取的 U 网络.与 STA/LTA、Kurtosis 等传统震相识别方法的对比结果表明,U 网络的均方根误差、命中率和查全率均优于 STA/LTA、Kurtosis 等传统的自动检测方法,与人工挑选结果的比对表明其准确识别出了 81% 和 79.1% 的 Pg、Sg 震相.

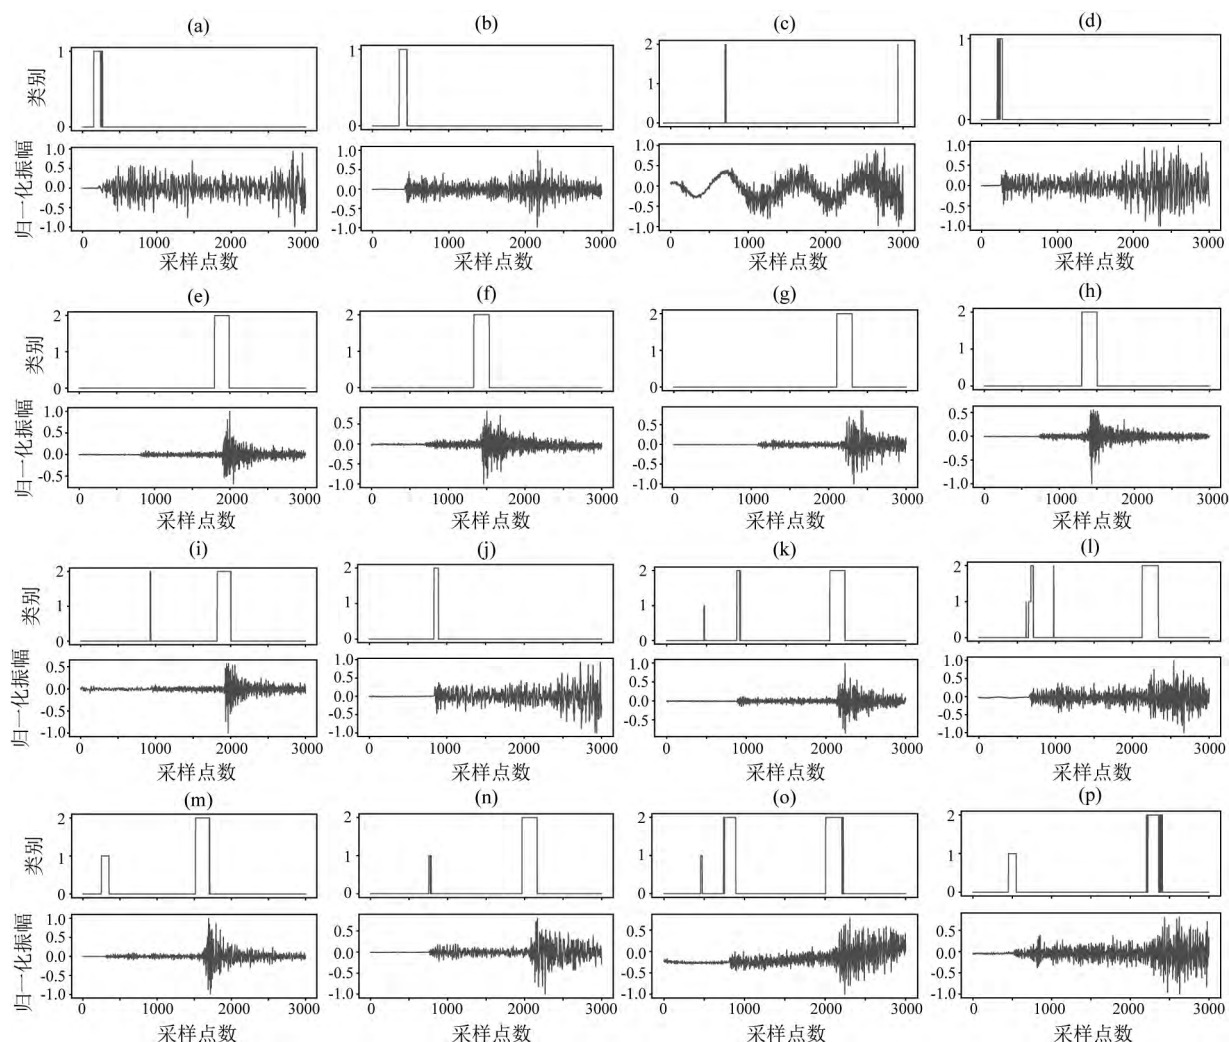


图 6 四种有代表性的检测结果

(a—d) 成功检测到 Pg 震相,漏检 Sg 震相; (e—h) 成功检测 Sg 震相,漏检 Pg 震相;

(i—l) 检测到 Pg 到时,但类型判断错误; (m—p) 成功检测到波形中所有震相。

Fig. 6 An example of the phase classification and arrival time picks by U-net on different waveforms

(a—d) Pg detected, Sg missed; (e—h) Sg detected, Pg missed; (i—l) Pg detected, but with wrong type;

(m—p) Both Pg and Sg detected.

U 网络在检测精度和稳定性上均明显优于传统方法,同时可以极小的计算开销应用于首都圈台网的实时地震数据快速 Pg、Sg 震相检测。当然,U 网络目前仍存在漏检和拾取震相不够精确的问题,后续工作包括扩充数据样本量(包括收集漏检样本与使用 5—10 年的波形数据)重新训练模型、使用传统的震相关联和定位等手段排除震相误检率和漏检率,并结合传统方法进行到时精确拾取。深度学习和人工智能技术未来将在实时地震学、地震早期预警和地震台网自动编目等业务上发挥越来越重要的作用。

致谢 感谢“余震捕捉—AI 大赛”提供汶川地震余震的波形和震相到时数据,感谢北京数字遥测地震

台网和河北省地震局提供连续波形数据和震相观测报告。感谢加州理工学院 Zachary Ross 博士提供震相到时自动拾取程序。

References

- Akaike H. 1974. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*. 19(6): 716-723.
- Akazawa T. 2004. A technique for automatic detection of onset time of P-and S-phases in strong motion records. 13th World Conference on Earthquake Engineering. Vancouver B C, Canada: International Association for Earthquake Engineering.
- Allen R V. 1978. Automatic earthquake recognition and timing from single traces. *Bulletin of the Seismological Society of America*, 68 (5): 1521-1532.

- Baer M, Kradolfer U. 1987. An automatic phase picker for local and teleseismic events. *Bulletin of the Seismological Society of America*, 77(4): 1437-1445.
- Fang L H, Wu Z L, Song K. 2017. Seism Olympics. *Seismological Research Letters*, 88(6): 1429-1430.
- Jiang Y R, Ning J Y. 2019. Automatic detection of seismic body-wave phases and determination of their arrival times based on support vector machine. *Chinese Journal of Geophysics* (in Chinese), 62(1): 361-373, doi: 10.6038/cjg2019M0442.
- Küperkoch L, Meier T, Lee J, et al. 2010. Automated determination of P-phase arrival times at regional and local distances using higher order statistics. *Geophysical Journal International*, 181(2): 1159-1170.
- Küperkoch L, Meier T, Brüstle A, et al. 2012. Automated determination of S-phase arrival times using auto regressive prediction: Application to local and regional distances. *Geophysical Journal International*, 188(2): 687-702.
- Kong Q K, Trugman D T, Ross Z E, et al. 2018. Machine learning in seismology: turning data into insights. *Seismological Research Letters*, 90(1): 3-14, doi: 10.1785/0220180259.
- Kortström J, Uski M, Tiira T. 2016. Automatic classification of seismic events within a regional seismograph network. *Computers & Geosciences*, 87: 22-30.
- Krischer L, Megies T, Barsch R, et al. 2015. ObsPy: a bridge for seismology into the scientific Python ecosystem. *Computational Science & Discovery*, 8(1): 014003, doi: 10.1088/1749-4699/8/1/014003.
- Liu H L, Wu Q J. 2017. Developments of research on earthquake detection and seismic phases picking. *Progress in Geophysics* (in Chinese), 32(3): 1000-1007, doi: 10.6038/pg20170308.
- Liu J S, Wan Gym Yao Z X. 2013. On micro-seismic first arrival identification: A case study. *Chinese Journal of Geophysics* (in Chinese), 56(5): 1660-1666, doi: 10.6038/cjg20130523.
- Long J, Shelhamer E, Darrell T. 2015. Fully convolutional networks for semantic segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. Boston, MA, USA: IEEE, 3431-3440.
- Maggi A, Ferrazzini V, Hibert C, et al. 2017. Implementation of a multistation approach for automated event classification at Piton de la Fournaise volcano. *Seismological Research Letters*, 88(3): 878-891.
- Perol T, Gharbi M, Denolle M. 2018. Convolutional neural network for earthquake detection and location. *Science Advances*, 4(2): e1700578.
- Ronneberger O, Fischer P, Brox T. 2015. Invited Talk: U-net Convolutional networks for biomedical image segmentation. *International Conference on Medical Image Computing and Computer-Assisted Intervention*, Cham: Springer, 234-241.
- Ross Z E, White M C, Vernon F L, et al. 2016. An improved algorithm for real-time S-wave picking with application to the (augmented) ANZA network in southern California. *Bulletin of the Seismological Society of America*, 106(5): 2013-2022, doi: 10.1785/0120150230.
- Ross Z E, Meier M A, Hauksson E. 2018. P wave arrival picking and first-motion polarity determination with deep learning. *Journal of Geophysical Research: Solid Earth*, 123(6): 5120-5129.
- Saragiotis C D, Hadjileontiadis L J, Panas S M. 2002. PAI-S/K: A robust automatic seismic P phase arrival identification scheme. *IEEE Transactions on Geoscience and Remote Sensing*, 40(6): 1395-1404.
- Sleeman R, Van Eck T. 1998. Robust automatic P-phase picking: an on-line implementation in the analysis of broadband seismogram recordings. *Physics of the Earth and Planetary Interiors*, 113(1-4): 265-275.
- Withers M, Aster R, Young C, et al. 1998. A comparison of select trigger algorithms for automated global seismic phase and event detection. *Bulletin of the Seismological Society of America*, 88(1): 95-106.
- Zhao M, Chen S, Yuen D. 2019. Waveform classification and seismic recognition by convolution neural network. *Chinese Journal of Geophysics* (in Chinese), 62(1): 374-382, doi: 10.6038/cjg2019M0151.
- Zhu W, Beroza G C. 2019. PhaseNet: a deep-neural-network-based seismic arrival-time picking method. *Geophysical Journal International*, 216(1): 261-273.

附中文参考文献

- 蒋一然, 宁杰远. 2019. 基于支持向量机的地震体波震相自动识别及到时自动拾取. *地球物理学报*, 62(1): 361-373, doi: 10.6038/cjg2019M0442.
- 李力, 张建国, 李盛乐. 2018. 余震自动识别技术研究进展. *地震研究*, 41(1): 1-13.
- 刘翰林, 吴庆举. 2017. 地震自动识别及震相自动拾取方法研究进展. *地球物理学进展*, 32(3): 1000-1007, doi: 10.6038/pg20170308.
- 刘劲松, 王赟, 姚振兴. 2013. 微地震信号到时自动拾取方法. *地球物理学报*, 56(5): 1660-1666, doi: 10.6038/cjg20130523.
- 赵明, 陈石, Yuen D. 2019. 基于深度学习卷积神经网络的地震波形自动分类与识别. *地球物理学报*, 62(1): 374-382, doi: 10.6038/cjg2019M0151.
- 中国地震局. 2017. DB/T66-2016 地震编目规范. 北京: 地震出版社.

(本文编辑 胡素芳)