

基于深度学习的地震相自动识别技术研究

吴 微^①, 谭绍泉^①, 王树华^①, 于会臻^①, 刘华夏^①

(^①中国石化胜利油田分公司 勘探开发研究院, 山东 东营, 257000)

摘要: 针对传统地震相分析方法难以有效表征地震相与地震数据间复杂的非线性映射关系, 而人工解释工作强度大、效率低的问题, 进行了基于深度卷积神经网络模型开展了地震相的智能识别技术研究。本文首先根据钻井解释和专家知识两种方式构建了地震相的训练样本库, 之后利用 Tensorflow 深度学习框架开展了网络参数寻优, 利用搭建好的网络模型进行了实际资料的训练和预测。测试结果表明, 利用深度卷积神经网络构建的河流相模型, 预测成功率高于 75%。因此, 深度卷积神经网络不仅可以很好地保持地震数据结构特征, 还可以基于多层网络结构挖掘数据中更深层的特征来提高地震相识别结果的可靠性, 印证了该技术在地震相识别中的巨大应用潜力。

关键词: 深度卷积神经网络; 地震相; 特征提取; 深度学习; Tensorflow

作者简介: 吴微(1984-), 男, 硕士, 工程师, 主要从事油气地球物理方法研究。

引言

地震相单元是利用地震参数对沉积层序进行沉积环境和岩相分析的基本单位。传统的地震相划分方法是通过肉眼观测来描述, 人工解释工作量巨大、解释效率低, 因此必须借助地震处理技术和信息技术加以提取、分析。随后出现的波形分类法、地震属性特征映射法以及基于地震地貌学的相划分法等几大类, 极大地促进了地震相解释效率和精度。但随着勘探的深入, 地震相识别难度与日俱增, 亟需引入新的技术来进一步挖掘地震相相关数据特征, 提高识别精度。

深度学习目前已成为人工智能领域中的一个最受关注的关键技术。在种类繁多的

1 深度卷积神经网络基本理论

与传统神经网络相比, 深度卷积神经网络更多地考虑了输入数据的空间结构特征,

深度学习网络模型中, 深度卷积神经网络(D-CNN)因其在空间结构特征提取方面的优势, 是应用效果最好的一种模型。从地震智能解释角度来看, 专家也是通过地震数据的结构特征差异来识别不同的解释目标, 与 D-CNN 最为擅长的图像识别具有相同的应用背景, 将其与地球物理相结合, 国内外研究人员成功的将其应用于地震数据处理^[1]、断层识别^[2]、全波形反演先验模型构建^[3]等勘探处理解释环节中, 并通过模型试验验证了该技术的适用能力。本文将在深度学习基本理论研究的基础上, 利用深度卷积神经网络(D-CNN)来进行实际资料的地震相识别, 提出一种新的地震相智能解释思路。

其基本单元主要包含卷积层、激活函数、池化层和全连接层这四个主要结构。例如在车辆图片识别中, 深度卷积神经网络模型可设置为图 1 所示结构。




图 1 深度卷积神经网络结构图

深度卷积神经网络结构确定之后, 需要根据样本数据及其对应的标签对网络的权重、偏置等关键参数进行训练, 以用于未

知数据的预测, 其过程是一个以样本数据为驱动的网络参数最优化过程。设其前向传播的数学表达公式如下表示:

$$y_i = \sigma(w_i * x + b_i) \quad (1)$$

式中, w_i —第 i 个卷积核 (滤波器); x —代表输入数据; b_i —第 i 个滤波器的偏置; σ —非线性函数, 为激活函数 (如 ReLU); y_i —网络模型的前向传播最终输出结果。

在得到训练数据的前向传播输出结果之后, 将其与训练样本的真实标签进行比较, 将预测误差利用反向传播算法来计算神经元的网络权重及偏置, 从而获得可以对未知数据进行预测和分类的最终网络模型。通常可采用预测样本标签与真实标签间的交叉熵最小来评价训练误差, 其目标函数表达式如下:

$$E = -\sum y_{pred} \log(y_{true}) \quad (2)$$

式中, y_{pred} —预测结果; y_{true} —真实标签; E —预测结果与实际结果的交叉熵。可利用随机下降、共轭梯度等算法对该目标函数进行最优化求解, 获得 w_i 和 b_i 等关键参数, 进而确定最终卷积网络模型。

2 深度卷积网络在地震相识别中的应用

本次研究是基于 D-CNN 方法开展地震相识别的, 具体技术流程主要包含以下五个步骤: ①地震数据预处理, 降低噪声干扰;

②基于测井等先验或专家解释构建地震相样本库; ③优选 D-CNN 网络结构, 初始化网络参数; ④样本库训练, 确定网络参数值; ⑤地震相预测。

为了验证上述技术流程的可靠性, 下面将结合河流相识别的应用测试具体介绍技术流程地震相训练数据集构建、网络模型结构及训练参数设置两个关键步骤的内容, 并对预测结果进行分析和对比。

2.1 地震相训练数据集的构建

本文采用的数据训练样本包含以下两种: 基于已知井解释标签的地震属性样本和基于专家解释成果标签的地震数据样本。下面将重点介绍如何利用专家知识形成样本。其中主要包含以下 4 个步骤:

(1) 地震资料等时预处理。利用地震沉积学的方法, 对地震数据进行处理, 保证地震层位的等时性。

(2) 专业解释人员根据河道地震数据进行样本分析, 在地震数据上圈定出典型的蓝色河道和红色河道的范围。本次河道数据共划分为 3 类相, 红色河道、蓝色河道和非河道相。

(3) 对地震数据进行样本切割。对选取好的样本进行分类, 给定标签, 例如将红色河道定义为 1 类 (图 2 (a)), 将蓝色河道为 2 类 (图 2 (b)), 将非河道样本为 0 类 (图 3 (c))。

(4) 对平面样本、剖面样本数据进行切割, 例如剖面数据按照 Inline 方向每 4 道切割一次, 作为最终样本数据, 如图 3 所示。



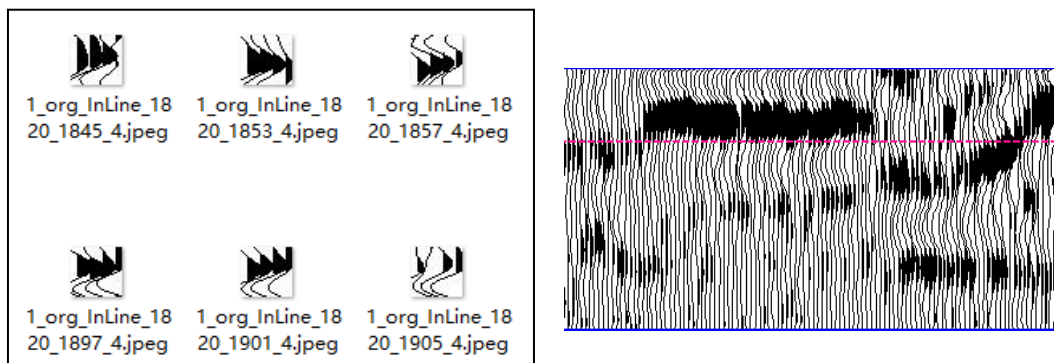


图 2 地震时间切片中的样本示例



(a) 部分平面小图片数据集



(b) 部分剖面小图片和大图片预测数据 (按右图 3350ms 红色线开窗选取)

图 3 部分预测样本数据集

2.2 深度学习框架选择及关键参数设置

样本构建之后, 选用了 TensorFlow 作为地震相识别的深度学习软件工具。下面介绍本次地震相识别应用中的关键参数设置。

(1) 样本输入参数设置

本次平面数据预测实验的训练数据集共有 7626 个样本, 三类样本的训练数据量都为 2542 个样本; 验证集样本数据集共有 1905 个样本, 三类样本的数据量都为 635 个; 本次剖面数据预测实验的训练数据共有 25488 个样本, 三类样本的训练数据量都为 8496 个; 验证集样本数据集总数为 6372, 三类样本的数据量都为 2124 个。

D-CNN 模型训练参数为: 样本分类数为 3; 模型迭代次数为 20000; 模型样本大小为 256×256 的矩阵。

(2) 网络结构

按照卷积神经网络基本结构, 本次训练选用了 5 层结构, 即包含了 5 次卷积层 (3×3)

+ReLU+池化层 (Maxpool 2×2) 的处理操作, 最后以全连接层+Soft-max 将特征提取结果进行分类并作为地震相预测结果, 参与到反向传播的网络模型参数寻优过程中。

(3) 批尺寸 (Batch_Size)

批尺寸参数主要指定了组合的大小, 该参数不易设置过大, 容易过拟合, 本次训练中设置批尺寸为 100。

(4) 学习率设定

本次训练将初始学习率设定为较小的数值, 取值 0.05, 在迭代过程中当训练样本验证结果精度不在提高时按照初始学习率的 1/10 递减, 以保证学习精度。

(5) 权重及偏置初始化。

偏置通常初始化为 0。

按照上述参数进行设置, 可以构建用于本文地震相样本训练的深度卷积神经网络模型结构, 如图 4 所示。




图 4 地震相识别卷积神经网络结构

2.3 模型效果分析

本次地震相识别的训练样本与预测数据都来自于同一研究区。将浅层的河流相数据作为训练样本，按照图 4 网络模型后对深层河流相进行了识别和预测，效果如图 5(c) 所示。同时利用随机森林进行了地震相分类的试验，如图 5 (b)。对比识别结果来看，

D-CNN 和随机森林都可识别出大致形态，但相比后者，由于采用了局部特征提取能力更强的卷积网络结构，D-CNN 所识别出的河道结构特征更加清晰，整体吻合率达到 75% 以上，但是对于小的河道及河道分叉处，还存在一些问题。




图 5 D-CNN 与随机森林对比图

(a 为地震切片图，b 为随机森林预测结果，c 为 D-CNN 预测结果，颜色代表不同类型河道预测结果)

3 结论及展望

利用深度卷积神经网络构建了地震相识别的技术流程，并开展河流相识别的应用测试分析，预测结果揭示了深度学习可较好地表征地震相与地震数据间的非线性映射关系。相比常规地震相自动识别技术，可在

保证效率的前提下，无须过多的人工干预便可获得可解释的地震相识别结果。下一步将开展三维地震相样本库构建工作，充分的发挥深度卷积神经网络模型的高维空间结构特征提取优势，进一步提高地震相识别效率及精度。

参考文献

- [1] Yuval Serfaty, Liron Itan, David Chase, Zvi Koren. Wavefield separation via principle component analysis and deep learning in the local angle domain[C]. SEG, 2017:991~995
- [2] Chiyuan Zhang, Charlie Frogner 与 TomasoPoggio. Automated Geophysical Feature Detection with Deep Learning[C]. GPU Technology Conference 2016:4~7.
- [3] Winston Lewis, Denes Vigh. Deep learning prior models from seismic images for full-waveform inversion[C]. SEG, 2017:1512~1517

联系人信息 (姓名: 吴微 单位: 中国石化胜利油田勘探开发研究院)